임베딩 모델을 통한 알고리즘 편향도 평가 서비스 배포

30219 윤영서

I. 개요

본 보고서는 융합주제탐구 프로그램(5.13.(월) - 7.17.(수))에서 진행하였던 [임베딩 모델을 통한 알고리즘 편향도 평가 서비스 개발]을 사용자들이 이용할 수 있도록 배포하는 과정과 결과를 다룸. 이전에 진행한 [임베딩 모델을 통한 알고리즘 편향도 평가 서비스 개발]에 대한 정보는 https://github.com/yys0527/fusion2024 에서 확인할 수 있음.

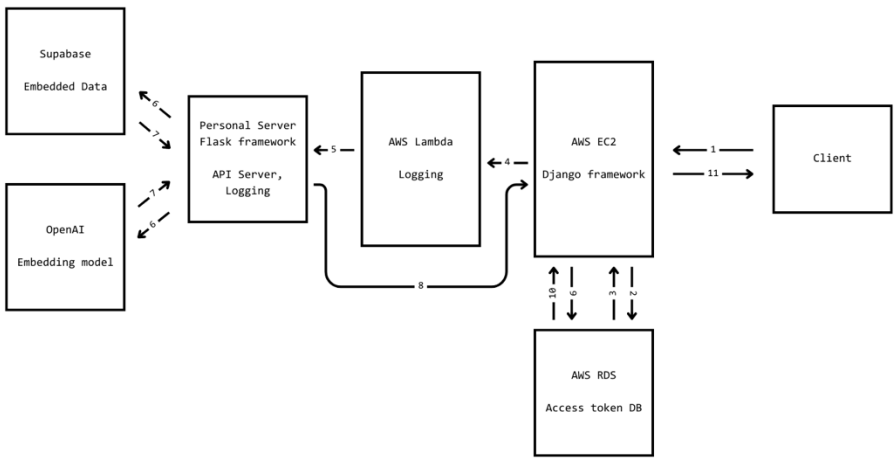
II. 요약

기존 계획이었던 구글 로그인을 통해 자동으로 영상 리스트를 불러오는 기능은 구글 측에서 프로젝트 승인을 해주지 않아 구현하지 못했다. 현재는 제목을 입력하면 관련된 분야를 띄워주는 형식으로 구현하였다. AWS의 다양한 서비스를 활용하였고 2학년 메이크올에서 사용하였던 Django 기반으로 구축하였다.

III. 상세

페이지 서빙을 위한 메인 서버는 AWS EC2 서비스를 이용하여 Django 프레임워크로 구성하였고, 임베딩 모델을 사용을 위한 API 구축을 위해 개인 서버에서 Flask 프레임워크를 활용하였다. EC2 메인 서버에서 API 서버로 직접 요청하지 않고 AWS Lambda를 통해 간접적으로 호출하여 보안성을 향상시켰다.

위는 서비스 호출 시 흐름도이다.



1. 클라이언트가 제목을 입력한다.
2·3. AWS EC2에서 요청을 받고 클라이언트에 대한 검증을 한 뒤 AWS RDS에 토큰을 저장한다.
   이때 검증이란, 사용자가 제대로 된 과정을 통해 호출하였는지, 사람이 맞는지 등을 확인한다.
4. 제목과 토큰을 파라미터로 AWS Lambda 함수를 호출한다.
5. AWS Lambda는 AWS 서비스 내 로그 시스템에 호출을 기록하고 제목과 토큰을 파라미터로
   개인 서버 내 API를 호출한다.
6. 전달받은 제목을 임베딩 모델에서 처리하기 위해 (참조된 Github 참고) Supabase DB내 임베딩
   데이터와 OpenAI의 임베딩 모델을 호출한다.
7. 응답받은 데이터를 개인 서버에서 처리한다.
8. 토큰과 API 호출 정보를 개인 서버에 저장하고 AWS EC2에 토큰과 API 응답 데이터를 파라미
   터로 전달한다.
9·10. API 응답이 정상적으로 수신되면 해당 토큰을 AWS RDS에서 삭제한다.
11. 클라이언트에게 결과값을 출력한다.